DIAGNÓSTICO DE OVERFITTING Y UNDERFITTING

Resumen ejecutivo

Diagnóstico: Resultado mixto: hay gap o mejora limitada frente al baseline; no basta para afirmar overfitting ni underfitting.

Dataset: 17,680,253 registros originales; agregación por provincia, cantón, parroquia y mes.
División temporal: train hasta 2023-12; validación 2024; prueba final 2025.
Ronda óptima base: 288 de 500; MAE validación: 26.77; MAE train: 15.40.
Gap MAE validación-train: 11.38; deterioro validación tras el mínimo: 4.00%.
Estrategia seleccionada: Parada temprana (288 árboles); MAE de prueba 2025: 22.81; baseline lag 12: 32.45.

Metodología

Se agregaron los eventos mensuales por parroquia y se construyeron rezagos usando solo información pasada. El preprocesamiento geográfico se ajustó con entrenamiento. Se monitorizó MAE por iteración y R^2 en checkpoints; se usó 2024 para seleccionar iteraciones/regularización y 2025 se reservó hasta la evaluación final.

Interpretación responsable

Las curvas identifican patrones de ajuste y generalización, no causalidad. Los conteos reflejan reportes y no están normalizados por población o afluencia turística. No se debe interpretar el resultado como nivel individual de peligro.

Estrategias implementadas

1) Parada temprana por MAE de validación. 2) Menor profundidad, mayor min_child_weight, regularización L1/L2 y submuestreo de columnas/filas.

Referencias técnicas

Chen & Guestrin (2016), XGBoost: A Scalable Tree Boosting System. KDD.
scikit-learn User Guide: Learning curves; TimeSeriesSplit y métricas de regresión.
XGBoost Python API: eval_set, evals_result y early_stopping_rounds.

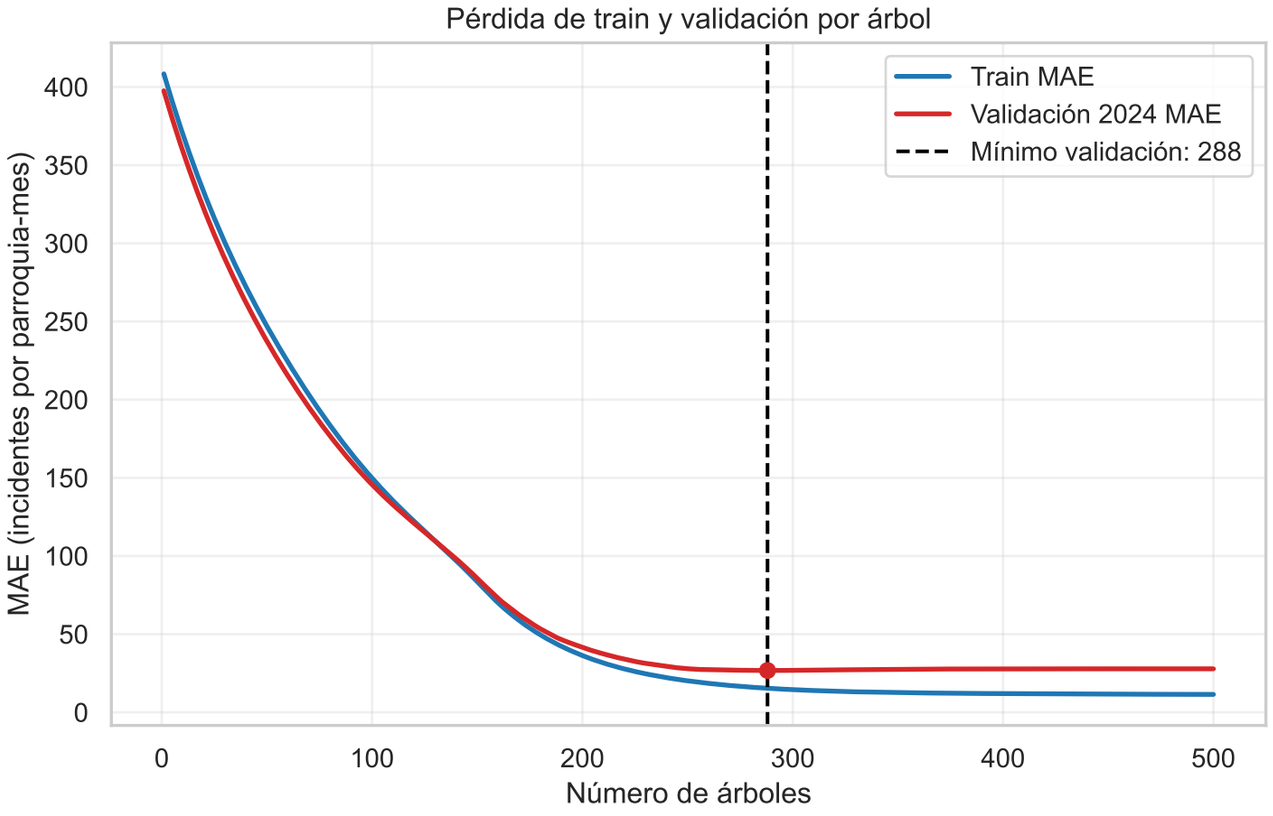
Pérdida de train y validación por árbol
Train MAE
Validación 2024 MAE
Mínimo validación: 288
MAE (incidentes por parroquia-mes)
Número de árboles
0
50
100
150
200
250
300
350
400
0
100
200
300
400
500

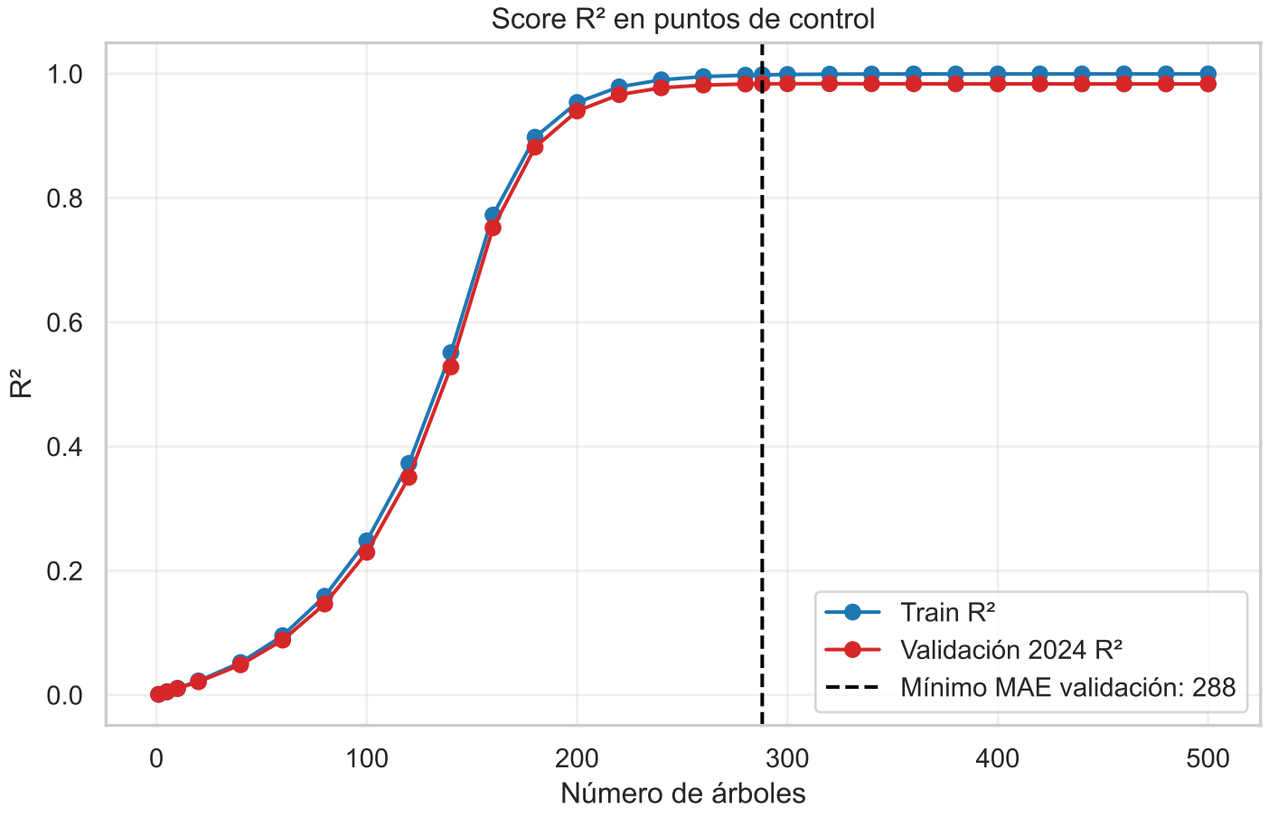
Score R² en puntos de control
Train R²
Validación 2024 R²
Mínimo MAE validación: 288
R²
Número de árboles
0.0
0.2
0.4
0.6
0.8
1.0
0
100
200
300
400
500

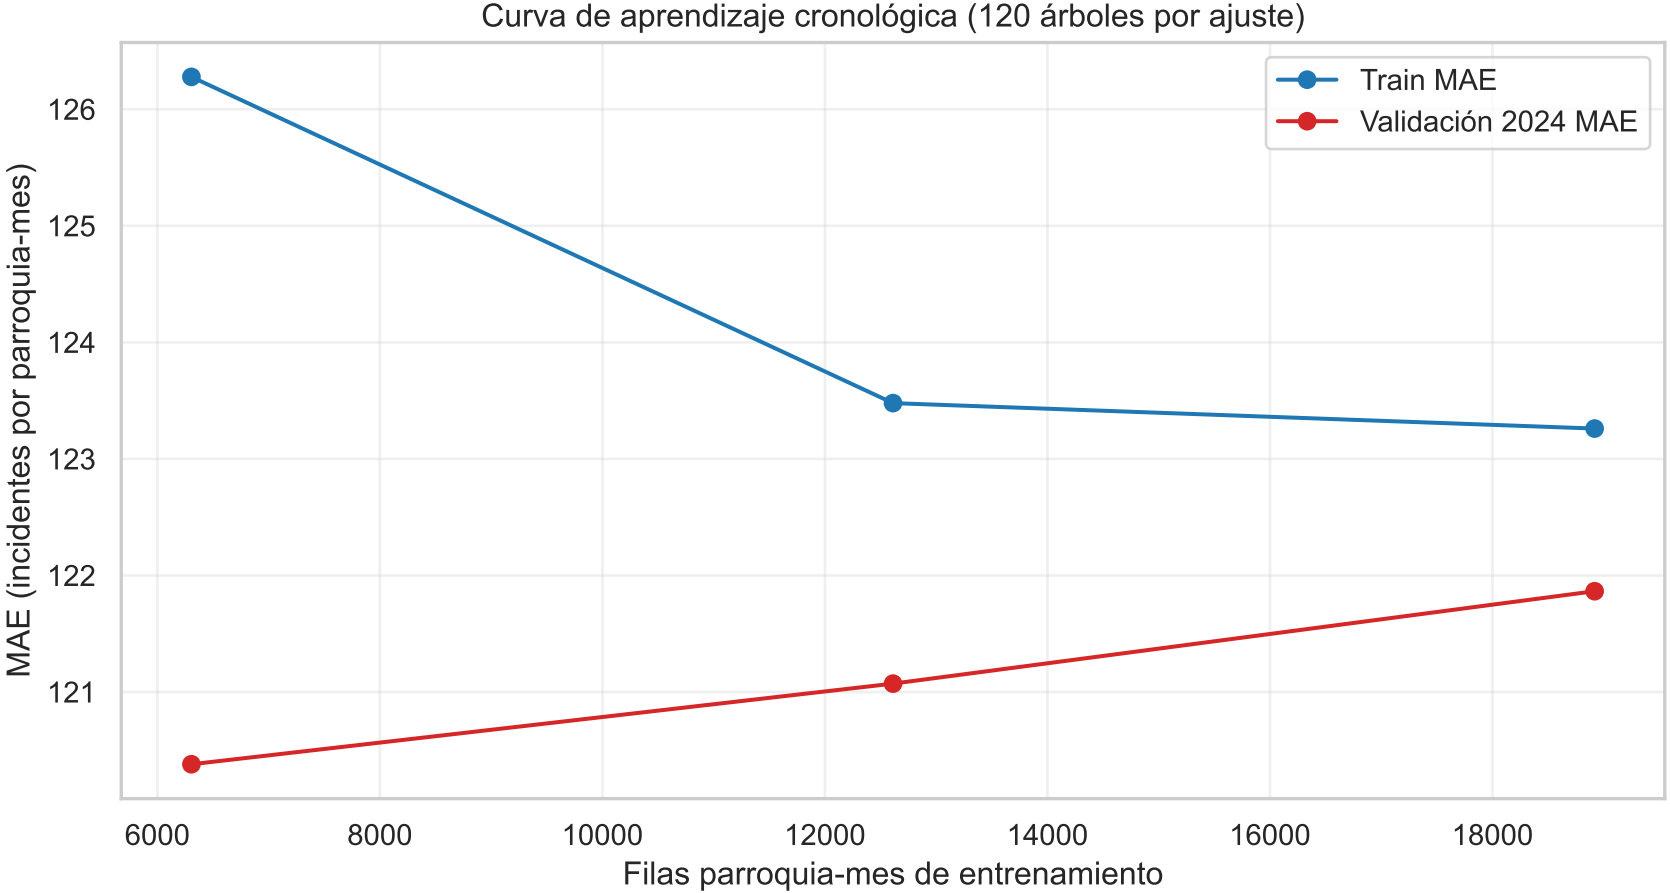
Curva de aprendizaje cronológica (120 árboles por ajuste)
Train MAE
Validación 2024 MAE
MAE (incidentes por parroquia-mes)
126
125
124
123
122
121
6000
8000
10000
12000
14000
16000
18000
Filas parroquia-mes de entrenamiento

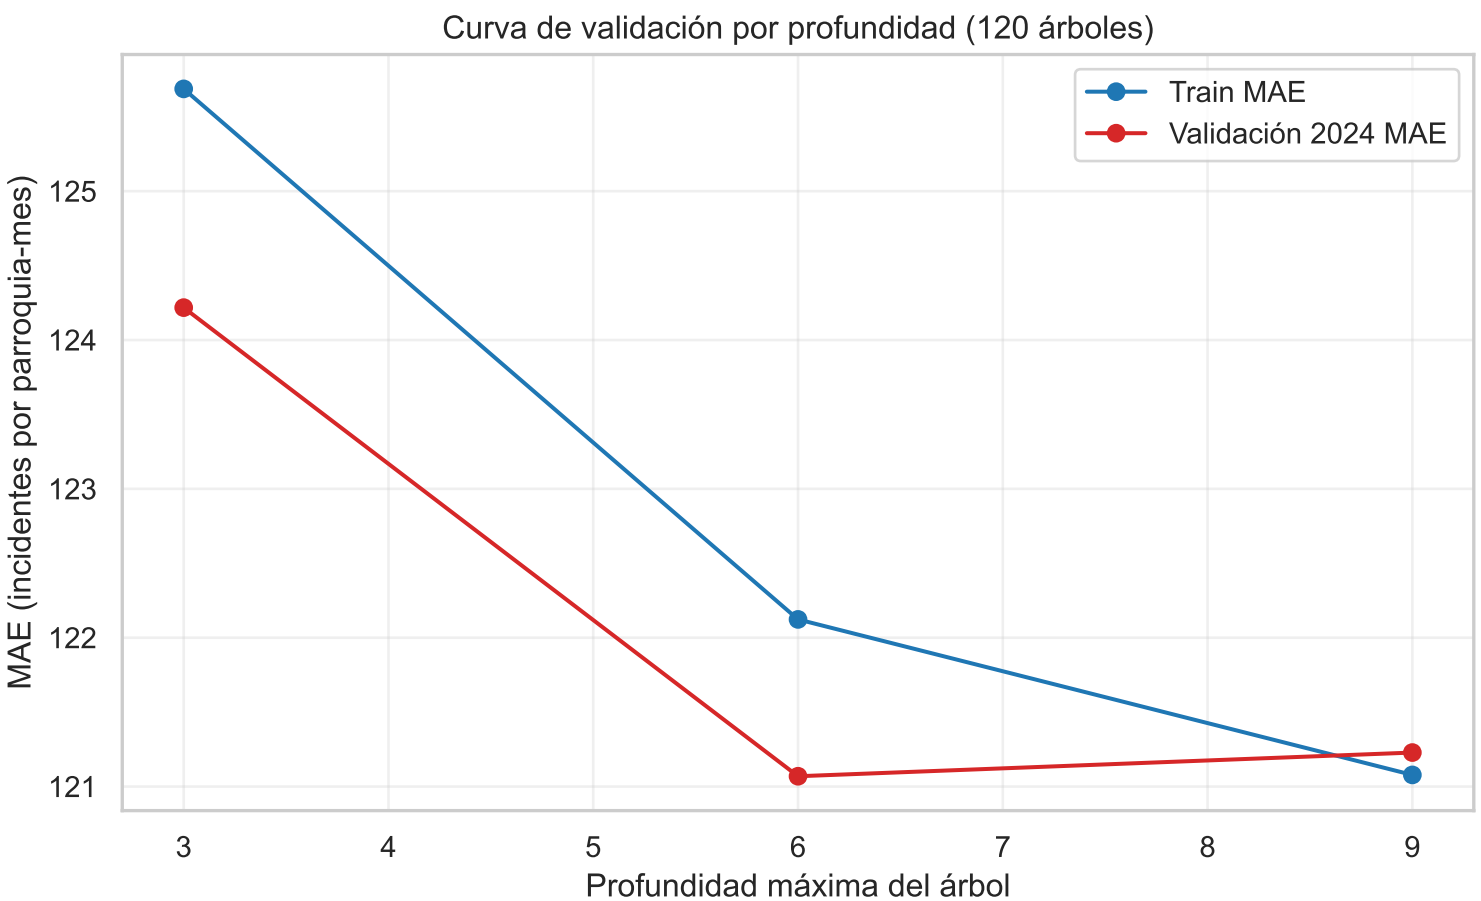
Curva de validación por profundidad (120 árboles)
Train MAE
Validación 2024 MAE
MAE (incidentes por parroquia-mes)
125
124
123
122
121
3
4
5
6
7
8
9
Profundidad máxima del árbol

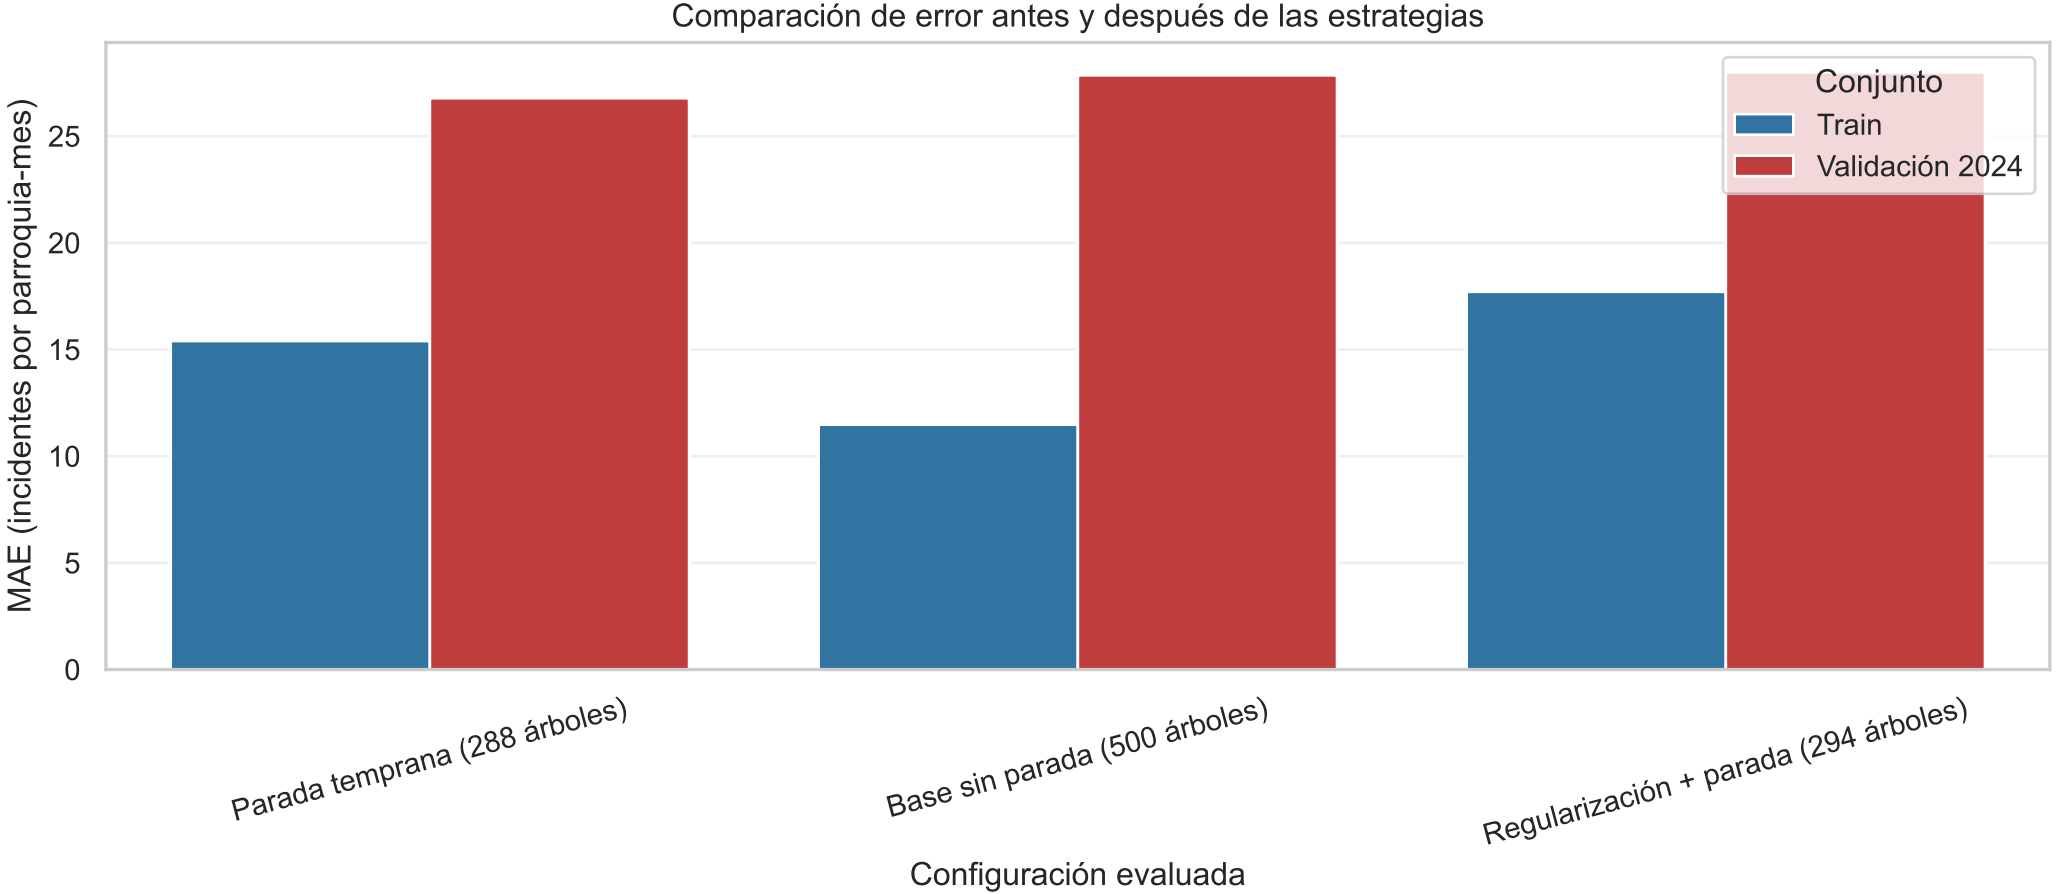
Comparación de error antes y después de las estrategias
MAE (incidentes por parroquia-mes)
0
5
10
15
20
25
Conjunto
Train
Validación 2024
Parada temprana (288 árboles)
Base sin parada (500 árboles)
Regularización + parada (294 árboles)
Configuración evaluada